



Elixirr



웹 데이터 수집 3

크롤링/스크래핑

본 자료의 일부 또는 전체는 Elixirr의 사전 서면 승인 없이 외부로 배포, 인용 또는 복제하는 행위를 금합니다.

© Copyright Elixirr

동적 페이지 크롤링

① 웹드라이버 생성



② 웹드라이버의 브라우저를 이용하여 목표 URL로 이동



③ 동적 콘텐츠 로딩



④ 필요 시 상호작용(클릭, 스크롤, 검색 등)



⑤ 데이터 추출

⑥ 데이터 저장





웹드라이버 객체 생성

- 크롬 브라우저를 조작하기 위한 웹드라이버 객체를 생성합니다.


```
# 라이브러리 import : selenium 웹드라이버
from selenium.webdriver import Chrome
```

```
# 크롬 웹드라이버 객체 생성
```

```
driver = Chrome()
```

브라우저 조작을 위한 객체

★ 브라우저를 닫으면 안되요.





셀레니움과 웹드라이버

- 셀레니움은 브라우저의 동작을 자동화 해줌
- 셀레니움은 WebDriver(웹드라이버)를 통해 브라우저를 제어
- 4.0부터 웹드라이버 파일 없이 가능하게 바뀌었음



브라우저 제어하기

- 브라우저 크기 제어하기

```
# 브라우저 크기 최소화
```

```
driver.minimize_window()
```

```
# 브라우저 크기 최대화
```

```
driver.maximize_window()
```



브라우저 제어하기

- 원하는 페이지로 이동합니다.

```
# 원하는 페이지로 이동하기
```

```
driver.get("https://www.naver.com")
```

```
driver.get("https://www.google.com")
```

```
driver.get("https://www.daum.net")
```




브라우저 제어하기

- 이전 페이지로 이동, 다음 페이지로 이동, 새로고침

```
# 이전 페이지로 이동
```

```
driver.back()
```

```
# 다음 페이지로 이동
```

```
driver.forward()
```

```
# 새로고침
```

```
driver.refresh()
```



브라우저 제어하기

- 브라우저 닫기

```
# 웹드라이버로 생성한 현재 창 종료  
driver.close()
```

Copyright © 2024 Jayoung Kim All rights reserved

```
# 웹드라이버로 생성한 모든 창 종료  
driver.quit()
```




브라우저 제어하기

- error

NoSuchWindowException: Message: no such window: target window already closed

┆ 웹드라이버로 생성한 브라우저를 닫았을 때 발생



웹페이지에서 가져올 요소 선택하기

- 브라우저 띄우기 : 웹드라이버 객체 생성하기

```
# 웹드라이버 객체 생성  
from selenium import webdriver  
driver = webdriver.Chrome()  
driver.get('http://www.naver.com')  
driver.maximize_window()
```

웹페이지에서 가져올 요소 선택하기

- 웹 요소 찾기 - 웹 요소의 CSS Selector 복사




※ 본 자료는 교육생 본인 학습용으로만 사용 가능합니다. 외부에 공개하지 말아주세요.

웹페이지에서 가져올 요소 선택하기



- 웹 요소 찾기 - 웹 요소의 CSS Selector 복사





웹페이지에서 요소 가져오기

- CSS Selector로 요소 찾기

웹드라이버.`find_element`(요소지정방법, “ ”)
선택자

CSS선택자로 요소 객체 가져오기

```
from selenium.webdriver.common.by import By
search = driver.find_element(By.CSS_SELECTOR, "#query")
search
```

```
<selenium.webdriver.remote.webelement.WebElement
(session="9f04fdbf074f98cd3e4d61483c2c08b3",
element="f.AAA796954FE13F5F17CA3A5CC40D87F9.d.EC22A0E3A
13BFD8A6A3DE2BBBA9B5DED.e.93")>
```

반환된 요소 객체

- 웹요소를 선택하는 방법 지정

- **By.CSS_SELECTOR**
- **By.ID**
- **By.CLASS_NAME**
- **By.NAME**
- **By.XPATH**
- **By.LINK_TEXT**
- **By.PARTIAL_LINK_TEXT**
- **By.TAG_NAME**



웹페이지에서 요소 가져오기

- CSS Selector로 요소 찾기

웹드라이버.`find_element`(요소지정방법, CSS Selector)

┆ 첫번째 결과 반환

웹드라이버.`find_elements`(요소지정방법, CSS Selector)

┆ 모든 결과 리스트로 반환



웹페이지의 요소 제어하기

- 입력창에 검색어 입력하기

```
# 입력창 요소 클릭하기
```

```
search.click()
```

← 요소객체.`click()`

```
# 검색어(텍스트) 입력하기
```

```
search.send_keys("인공지능")
```

← 요소객체.`send_keys("텍스트")`


웹페이지의 요소 제어하기

■ 엔터키 입력하기

요소.**send_keys**(특수키)

엔터키 입력하기

```
from selenium.webdriver.common.keys import Keys
search.send_keys(Keys.ENTER)
```



■ 특수키 사용

- **Keys.ENTER**
 - **Keys.TAB**
 - **Keys.SHIFT**
 - **Keys.CONTROL**
 - **Keys.ALT**
 - **Keys.SPACE**
 - **Keys.BACKSPACE**
 - **Keys.DELETE**
 - **Keys.LEFT**
 - **Keys.RIGHT**
 - **Keys.UP**
 - **Keys.DOWN**
 - **Keys.F1~Keys.F12**
- 등...

※ dir(Keys)



웹페이지의 요소 제어하기

- 순차적으로 키 입력하기

```
# 순차적으로 키 입력하기
```

```
search.send_keys("인공지능", Keys.ENTER)
```



웹페이지의 요소 제어하기

- 브라우저 닫기

```
# 브라우저 닫기  
driver.quit()
```



네이버 뉴스 댓글 수집

1. 전체 댓글의 갯수 가져오기
2. 사용자에게 수집할 댓글 수 입력받기
3. 댓글 수집하기
4. 파일로 저장하기

라이브러리 import

```
from selenium import webdriver
from selenium.webdriver.common.by import By
from selenium.webdriver.common.keys import Keys
import pandas as pd
import numpy as np
import time
import math
```



웹드라이버 생성 및 페이지 이동

```
driver = webdriver.Chrome()
```

```
# 웹페이지 접근
```

```
url = 'https://n.news.naver.com/article/005/0001707120'
```

```
driver.get(url)
```

```
driver.maximize_window()
```

```
time.sleep(2)
```



전체 댓글 수 추출

국민일보
PICK

“요새 누가 나이키 신어요”... 하루 만에 시총 39조 증발

입력 2024.06.29. 오전 9:38 · 수정 2024.06.29. 오후 5:49 기사원문


김지훈 기자

 118
 752







나이키 주가 -20% ‘공포의 급락’
매출 줄고 미래 실적도 부정적
파리 올림픽서 실적 만회 노릴듯



전체 댓글 수 추출

```
review_total_cnt = driver.find_element(By.CSS_SELECTOR, "#comment_count").text  
print(review_total_cnt)
```

```
time.sleep(2)
```

752

댓글 화면으로 이동

국민일보

PICK

“요새 누가 나이키 신어요”... 하루 만에 시총 39조 증발

입력 2024.06.29. 오전 9:38 · 수정 2024.06.29. 오후 5:49 기사원문

 김지훈 기자

 118

 752

클릭







나이키 주가 -20% '공포의 급락'

매출 줄고 미래 실적도 부정적

파리 올림픽서 실적 만회 노릴듯



댓글 화면으로 이동

```
driver.find_element(By.CSS_SELECTOR, '#comment_count').click()
```

```
time.sleep(3)
```



더보기 클릭하여 모든 댓글 보이기



aoir****

2024.06.29. 10:56

팔로우

솔직히 메이커 값임. 이념들 인체공학적 편안함 같은건 신경도 안쓰는거 같은데. 그저께 나이키 슬리퍼 샀는데 역시나 그 지같은 착용감ㅏㅏ

답글

19

3



gusq****

2024.06.29. 16:26

팔로우

동양인은 발볼 넓어서 나이키랑은 잘 안맞는듯

답글

17

2

더보기 ▼

한번에 20개씩 추가로 보여줌



더보기 클릭하여 모든 댓글 보이기

```
# -----  
# 더보기 클릭 횟수  
# 더보기 클릭 할 때마다 20개의 댓글이 추가로 보여짐  
# ceil(전체 댓글 수/20)  
# -----  
# pagecnt = math.ceil(int(review_total_cnt)/20)-1  
pagecnt = 3  
  
# -----  
# 더보기 클릭  
# -----  
for i in range(pagecnt):  
    print(f'{i}번째 페이지 로드중')  
    driver.find_element(By.CSS_SELECTOR, '.u_cbox_btn_more').click()  
    time.sleep(2)  
  
print('모든 댓글 로드 완료')
```


데이터 추출

```
# -----  
# 댓글, 좋아요갯수, 싫어요갯수, 날짜  
# -----  
comments = driver.find_elements(By.CSS_SELECTOR, ".u_cbox_area")  
comment_list = []  
for comment in comments:  
    try: review = comment.find_element(By.CSS_SELECTOR, ".u_cbox_contents").text  
    except: review = np.nan  
  
    try: reply_cnt = comment.find_element(By.CSS_SELECTOR, ".u_cbox_reply_cnt").text  
    except: reply_cnt = np.nan  
  
    try: recomm = comment.find_element(By.CSS_SELECTOR, ".u_cbox_cnt_recomm").text  
    except: recomm = np.nan  
  
    try: unrecomm = comment.find_element(By.CSS_SELECTOR, ".u_cbox_cnt_unrecomm").text  
    except: unrecomm = np.nan  
  
    try: date = comment.find_element(By.CSS_SELECTOR, ".u_cbox_date").text  
    except: date = np.nan  
  
    comment_list.append({"review":review, "reply_cnt":reply_cnt,  
                        "recomm":recomm, "unrecomm":unrecomm, "date":date})
```



데이터 저장

```
# -----  
# 데이터프레임 생성  
# -----  
df = pd.DataFrame(comment_list)  
  
# -----  
# 파일로 저장  
# -----  
prefix = datetime.now().strftime('%Y%m%d_%H%M%S')  
file_path = f'data/댓글/{prefix}네이버뉴스_나이키'  
df.to_csv(file_path+'.csv')  
df.to_excel(file_path+'.xlsx')
```

대기 기법

- 웹페이지가 완전히 로드되거나 특정 요소가 나타날 때까지 기다리기 위한 방법

- **time.sleep()**

- ✓ 장점 : 사용법이 간단하지만
- ✓ 단점 : 네트워크 상황에 따라 부족하거나 과도할 수 있음

- **암시적 대기(Implicit Wait)**

- ✓ WebDriver 전체에 대해 요소를 찾을 때까지 최대 지정시간동안 반복적으로 DOM을 탐색하며 대기
- ✓ 장점 : 코드 전체에 적용되어 편리하고, 요소가 빨리 로드되면 바로 다음 단계로 진행
- ✓ 단점 : 특정 요소에만 대기를 세밀하게 적용할 수 없음. 동적 요소가 많은 페이지에서는 부족할 수 있음.

- **명시적 대기(Explicit Wait) ← 권장**

- ✓ 특정 요소가 특정 조건을 만족할 때까지, 최대 지정시간 동안 대기
- ✓ 장점 : 특정 요소에 대해 세밀하게 조건을 설정할 수 있어, 동적 웹페이지에 가장 적합
- ✓ 단점 : 각 요소마다 대기 코드를 작성해야 하므로 코드가 길어질 수 있음.

명시적 대기

- 특정 조건이 충족될 때까지 코드 실행을 지연시키는 방법

- ✓ WebdriverWait과 expected_condition(EC)을 조합하여 사용

WebdriverWait(웹드라이버, 최대대기시간).until(조건함수)

- || 조건이 충족되면 .until()은 WebElement나 True 등을 반환
- || 시간 초과 시 TimeoutException을 일으킴

명시적 대기

- 특정 조건이 충족될 때까지 코드 실행을 지연시키는 방법

[예시코드]

```
from selenium.webdriver.common.by import By
from selenium.webdriver.support.ui import WebDriverWait
from selenium.webdriver.support import expected_conditions as EC

driver = webdriver.Chrome()
driver.get("https://example.com")
# ID가 'myElement'인 요소가 나타날 때까지 최대 10초 대기
element = WebDriverWait(driver, 10).until(
    EC.presence_of_element_located((By.ID, "myElement"))
)
```

조건함수

명시적 대기

- 주요 Excepted Condition

대기 조건	확인하는 내용
presence_of_element_located	요소가 DOM 상에 존재하는지 여부 요소(WebElement) 반환
visibility_of_element_located	요소가 DOM 상에 존재하고 화면에 표시되는지 여부 요소(WebElement) 반환
element_to_be_clickable	요소가 보이고 있으며 클릭 가능한 상태인지의 여부 요소(WebElement) 반환
invisibility_of_element_located	특정 요소가 더 이상 화면에 보이지 않고 DOM에 존재하지 않는지 여부 True/False 반환