



Elixirr




웹 데이터 수집 2

크롤링/스크래핑

본 자료의 일부 또는 전체는 Elixirr의 사전 서면 승인 없이 외부로 배포, 인용 또는 복제하는 행위를 금합니다.

정적 페이지 크롤링



③ 웹페이지 파싱 및 데이터 추출

④ 데이터 저장

웹페이지 요청하여 응답 받기

- HTTP 요청 및 응답객체 생성

※requests 라이브러리 주요 사용 방법

```
import requests
```

```
URL = 'https://jsonplaceholder.typicode.com/posts'
```

```
response = requests.get(url) # HTTP 요청 및 응답객체 생성
```

```
print(response.status_code) # HTTP 상태 코드
```

```
print(response.text) # 응답 본문(텍스트 형태)
```

```
print(response.content) # 응답 본문(바이너리 형태)
```

```
print(response.json()) # JSON 응답을 파싱
```

웹페이지 요청하여 응답 받기

- HTTP 요청 및 응답객체 생성

```
import requests

#크롤링 할 웹페이지 url
url = "https://startcoding.pythonanywhere.com/basic"

# 웹페이지 요청
response = requests.get(url)


status_code = response.status_code # 상태코드(200:성공)
html = response.text # 응답받은 html 페이지
```

응답받은 객체

웹페이지 요청

html 문서 파싱 및 데이터 추출

- HTML/XML 문서를 파싱하여 분석 가능한 객체로 생성



html 문서 파싱 및 데이터 추출

BeautifulSoup

▪ parser : HTML/XML 문서를 해석하여 구조화된 데이터로 변환하는 도구

html.parser
Python 표준 라이브러리에서 제공
별도의 설치가 필요 없음.

파서	사용법	장점	단점
파이썬의 html.parser	BeautifulSoup(markup, "html.parser")	- 보통 속도 - 파이썬 2.7.3, 3.2.2 이상 버전에서 호환됨	파이썬 2.7.3 또는 3.2.2 이전버전에서 호환되지 않음
lxml's HTML parser	BeautifulSoup(markup, "lxml")	- 매우 빠름 - 호환성	외부 C에 의존함
lxml's XML parser	BeautifulSoup(markup, "lxml-xml") BeautifulSoup(markup, "xml")	매우 빠름	- XML 파서만 지원 - 외부 C에 의존함
html5lib	BeautifulSoup(markup, "html5lib")	- 호환성이 높음 - 웹브라우저와 같은 방식으로 페이지 파싱 - 유효한 HTML5를 만듦	매우 느림

html 문서 파싱 및 데이터 추출

- HTML 요소 추출

CSS선택자로 검색하여 처음 나오는 요소 1개 추출하기

```
soup.select_one("CSS선택자")
```

CSS선택자로 검색하여 모든 태그를 리스트로 추출

```
soup.select("CSS선택자")
```

html 문서 파싱 및 데이터 추출

▪ CSS 선택자 찾기



html 문서 파싱 및 데이터 추출

- HTML 요소 추출을 위한 CSS 선택자 찾기

증권홈 > 뉴스 > 주요뉴스

속보 하나증권 '원

주요뉴스

a 275.54 x 14



쿠팡, '쿠팡이츠' 중심 신사업 수익성 개선 기대

쿠팡 주가가 지지부진한 모습이다. 관세 이슈로 인한 글로벌 교역
출 경기와 내수 경기에 대한 우려가 심화됐기.. 이데일리 | 2025

• articleSubject > a

```
class="thumb">...</dt>
<dd class="articleSubject">
...
<a href="https://n.news.naver.com/mnews/article/018/0005991986" target="_blank">쿠팡, '쿠팡이츠' 중심 신사업 수익성 개선 기대</a> == $0
</dd>
<dd class="articleSummary">...</dd>
::after
```

◀ nainNewsList._replaceNewsLink ul.newsList li.block1 dl dd.articleSubject a ▶

html 문서 파싱 및 데이터 추출

- HTML 요소 1개(첫번째 요소) 추출

```
soup.select_one(".articleSubject")
```

```
<dd class="articleSubject"> <a
href="/news/news_read.naver?article_id=0005315061&office_id=009&mode=m
ainnews&type=&date=2024-06-06&page=1">전기차 밸류체인 구조조정...SK 이어
도레이도 분리막 '철수'</a> </dd>
```

자식요소추출

```
soup.select_one(".articleSubject > a")
```

```
<a
href="/news/news_read.naver?article_id=0005315061&office_id=009&mode=m
ainnews&type=&date=2024-06-06&page=1">전기차 밸류체인 구조조정...SK 이어
도레이도 분리막 '철수'</a>
```

html 문서 파싱 및 데이터 추출

HTML 요소로부터 텍스트 및 속성 추출

```
soup.select_one(".articleSubject > a").text
```

|| 텍스트 추출

```
"\n전기차 밸류체인 구조조정...SK 이어 도레이도 분리막 '철수'\n"
```

```
soup.select_one(".articleSubject > a").attrs
```

|| 속성추출

```
{'href':  
'/news/news_read.naver?article_id=0005315061&office_id=009&mode=mainnews&type  
=&date=2024-06-06&page=1'}
```

|| dict

```
soup.select_one(".articleSubject > a").attrs["href"]
```

|| 특정속성 추출

```
'/news/news_read.naver?article_id=0005315061&office_id=009&mode=mainnews&type  
=&date=2024-06-06&page=1'
```

html 문서 파싱 및 데이터 추출

▪ HTML 요소 리스트 추출

```
titles = soup.select(".articleSubject > a")
print(titles)
```

```
[<a
href="/news/news_read.naver?article_id=0005315061&office_id=009&mode=ma
innews&type=&date=2024-06-06&page=1">전기차 밸류체인 구조조정...SK 이어
도레이도 분리막 '철수'</a>, <a
href="/news/news_read.naver?article_id=0002878559&office_id=029&mode=ma
innews&type=&date=2024-06-06&page=1">`부자아빠` 저자 기요사키 "비트코
인, 8월까지 35만달러 돌파"</a>, <a
href="/news/news_read.naver?article_id=0001701629&office_id=005&mode=ma
innews&type=&date=2024-06-06&page=1">엔비디아 시총 3조 달러 뚫었다... '7
만전자'의 9배</a>, ...
<a
href="/news/news_read.naver?article_id=0005314920&office_id=009&mode=ma
innews&type=&date=2024-06-06&page=1">[단독] 미국 가정식 프랜차이즈 샤이
바나, 매물로 나왔다</a>]
```

네이버 증권 뉴스 수집

특정 날짜의 뉴스데이터 수집

<https://finance.naver.com/news/mainnews.naver>

데이터 수집

- 제목
- 상세페이지링크
- 내용
- 언론사
- 날짜



모든 아티클 크롤링

- 모든 아티클 목록 가져오기

```
articles = soup.select(".block1")
```


모든 아티클 크롤링

- 아티클 목록으로 반복하기

```
articles = soup.select(".block1")  
for article in articles:  
    pass
```

모든 아티클 크롤링

- 아티클 별 제목, 상세페이지url, 내용, 언론사, 날짜 가져오기

```
articles = soup.select(".block1")
for article in articles:
    title = article.select_one(".articleSubject").text.strip()
    link = article.select_one(".articleSubject > a").attrs["href"]
    content = article.select_one(".articleSummary").contents[0].strip()
    press = article.select_one(".press").text
    date = article.select_one(".wdate").text
```

모든 아티클 크롤링

- 리스트에 각각의 아티클 내용 담기

```
articles = soup.select(".block1")
article_list = []
for article in articles:
    title = article.select_one(".articleSubject").text.strip()
    link = article.select_one(".articleSubject > a").attrs["href"]
    content = article.select_one(".articleSummary").contents[0].strip()
    press = article.select_one(".press").text
    date = article.select_one(".wdate").text
    article_list.append([title, link, , content, press, date, article_list])
```

모든 아티클 크롤링

■ 데이터프레임 만들기

```
import pandas as pd

df = pd.DataFrame(article_list,
                  columns = ["제목", "상세페이지url", "요약내용", "언론사", "날짜"])

df.head()
```

	제목	상세페이지url	요약내용	언론사	날짜
0	전기차 밸류체인 구조조정...SK 이어 도레 이도 분리막 '철수'	/news/news_read.naver? article_id=0005315061&of...	분리막사업 매각 배경 고금리에 경기부진 겹쳐 전기차 일시 적 수요정체 분리막 공장 가...	매일경제	2024-06-06 17:42:10
1	'부자아빠' 저자 기요사키 "비트코인, 8월 까지 35만달러 돌파"	/news/news_read.naver? article_id=0002878559&of...	가상화폐 대장주 비트코인이 7만1000달러선에서 움직이고 있다. 이 가운데 세계적인...	디지털타 임스	2024-06-06 17:36:07
2	엔비디아 시총 3조 달러 뚫었다... '7만전 자'의 9배	/news/news_read.naver? article_id=0001701629&of...	전 세계 인공지능(AI) 반도체 시장의 80%를 장악한 미국 엔 비디아가 시가총액 3...	국민일보	2024-06-06 17:35:12
3	유럽 부동산 펀드 '비상'...현실 손실화에 추가 도산 우려	/news/news_read.naver? article_id=0005757639&of...	미국의 상업용 부동산 펀드 부실을 중심으로 시작한 해외 부 동산 펀드에 대한 대규모 ...	이데일리	2024-06-06 17:34:11
4	巨野의 '코인세 공제'...증시 밸류업 흔들 다	/news/news_read.naver? article_id=0004350080&of...	정기권에서 금융투자소득세 폐지를 놓고 공방이 가열되고 있는 가운데 금투세와 함께 시...	서울경제	2024-06-06 17:31:24

모든 아티클 크롤링

■ 엑셀로 저장하기

```
import openpyxl
df.to_excel("증권뉴스.xlsx", index=False)

# 확인하기
pd.read_excel("증권뉴스.xlsx")
```

여러 페이지 크롤링

- 페이지 이동에 따른 url 구조 확인하기

`https://finance.naver.com/news/mainnews.naver?&page=1`

`https://finance.naver.com/news/mainnews.naver?&page=2`

`https://finance.naver.com/news/mainnews.naver?&page=3`

...

여러 페이지 크롤링

■ 3페이지까지 크롤링

```
article_list = []
for page in range(1,4):
    time.sleep(1)
    print(f'{page}page>>>')
    url = "https://finance.naver.com/news/mainnews.naver?&page="+str(page)
    response = requests.get(url)
    html = response.text # 응답받은 html 페이지
    soup = BeautifulSoup(html, 'html.parser')

    # 크롤링
    articles = soup.select(".block1")
    for article in articles:
        title = article.select_one(".articleSubject").text.strip()
        link = article.select_one(".articleSubject > a").attrs["href"]
        content = article.select_one(".articleSummary").contents[0].strip()
        press = article.select_one(".press").text
        date = article.select_one(".wdate").text
        article_list.append([title,link,content,press,date])
```

여러 페이지 크롤링

■ 마지막 페이지까지 크롤링

페이징 ui 구조 확인

1 | 2 | 3 | 4 | 5 | 맨뒤 >>

<< 맨앞 | 1 | 2 | 3 | 4 | 5 |

마지막 페이지에는
[맨뒤] 없음

여러 페이지 크롤링

■ 마지막 페이지까지 크롤링

```
article_list = []
page = 1
while True:
    time.sleep(1)
    print(f'{page}page>>>')
    url = "https://finance.naver.com/news/mainnews.naver?&page="+str(page)
    response = requests.get(url)
    html = response.text # 응답받은 html 페이지
    soup = BeautifulSoup(html, 'html.parser')

    # 크롤링
    articles = soup.select(".block1")
    for article in articles:
        title = article.select_one(".articleSubject").text.strip()
        link = article.select_one(".articleSubject > a").attrs["href"]
        content = article.select_one(".articleSummary").contents[0].strip()
        press = article.select_one(".press").text
        date = article.select_one(".wdate").text
        article_list.append([title,link,content,press,date])

    if soup.select_one('.pgRR')==None: break
    else: page+=1
```

|| [맨뒤] 태그가 없으면 반복 종료, 있으면 페이지에 1 더하기